[stw] 文本結構化標記語言

(a.k.a.,) Jing's Structured Text Markup Language

黄 京 (RadioNoiseE)

西历 2023 年 6 月 20 日

概要

本文档将介绍 JSTML,一种基于 C 语言构建的(极简易的)文本结构化标记语言;而它的设计目的是,用来写同学录。

其本质上是一个基于下推自动机*¹的解析器,因设计用途的局限性,不允许出现嵌套等魔法。容错模型也较为简陋,而性能则没有进行任何优化(读入输出纯靠栈)。

将先介绍数据结构、语法,而后介绍实现细节、自动化 Lua 脚本、PLAIN-TEX 输出样式文件等信息。

1 一些约定

- 下文中将会用「她」「其」等代词表示 JSTML 语言的独立解释器,即她的可执行文件。
- 将会用小型大写西文字母(SMALL CAPS)表示脚本语言、宏语言、标记语言等,还用来表示某些特定的操作系统名称。
- 使用方全角引号(「」)表示被它们划定的特定字符;使用尖括号与斜体表示可选项描述或不需要显示输入的内容,不代表实际键入的字符。
- 将会使用脚注补充一些多馀信息,且响应国家倡议:正文中使用符合现行语言标准的简化字和两个全角空格宽的缩进。

2 字类型及数据类型、结构

2.1 字类型

在她眼中,所有的输入都属于字(token),及一个或一些字符(character)的集合。而字又被分为五种类别*2:

分界符 如其名,自然是作为两种数据结构的界定出现。其中,「<」被用作表示开始、而「>」表示结束。

标示符 标示其中一种数据结构的开始与结束。其中,「*」为开,而「/」为关。

汉字 主要的处理对象,也就是这门语言「标记」的东西。由几乎所以不属于其它三类的字符组成。

^{*1} 一个很哲学的术语。

^{*&}lt;sup>2</sup> 致敬高德纳教授所创 T_EX 的类别码(category code),由于大部分(如果不是全部的话)标记语言都有类别码的概念、而 T_EX 实际上是宏语言,故特此说明。

空白 包括空格*3及横向制表符(tab)。

换行 指在 MACINTOSH 或 UNIX、POSIX 等系统下的回车换行符。

2.2 数据类型

上述的四种字组合便有了能够被她处理的, 合法的唯二的数据类型: 狗牌(tag)和八卦(text)。

其中狗牌表示对八卦的一个概述,故理论上应短小而精悍。也因此,她内部分配给狗牌的空间仅有 19 个字符长度*⁴。也就是说,如果你往狗牌里硬塞超过 19 个汉字,会导致分段错误或栈溢出*⁵,报错并继续运行(毕竟它只是狗牌呐)。

而另一种八卦所能容纳的字符就多多了, 达 8192 个字符的长度。八卦与狗牌一一对应, 是对狗牌的展开说明, 也可以是扩充等一切合理(或不合理)的用途。

2.3 数据结构

在两种数据类型的基础上,又构建了两种数据结构(即,用来组织/表示数据类型的东西):片段和累牍。 一个片段只能出现在一行之中*6,而累牍则理论上横跨数行。

片段的狗牌被使用一对分界符界定,而八卦则被结束分界符和换行符界定,语法如下:

」〈Optional Space〉<〈Optional Space〉狗牌〈Optional Space〉>〈Optional Space〉八卦〈Carriage Return〉

而〈Optional Space〉表示可选的被忽略的空白字类型、〈Carriage Return〉表示换行符(回车)。

累牍的狗牌需被括在分界符中,作为八卦的界定出现两次;同时需要使用累牍标示开、关来标识。语法如下:

- 1 〈Optional Space〉<〈Optional Space〉*〈Optional Space〉狗牌〈Optional Space〉>〈Optional Space / Newline〉
- 2 〈Optional Space〉八卦〈Carriage Return〉
- 3 ⟨Ditto, Iteration / Recurse⟩
- ${}_4\ \langle Optional\ Space
 angle <\langle Optional\ Space
 angle /\langle Optional\ Space
 angle >$

其中,〈Optional Space / Newline〉表示可选的空白类字符、〈Ditto, Iteration / Recurse〉代表对上一条语句的不限次数的重复*7。

3 参考范例

给出一个实际使用本标记语言的范例(仅供参考、雷同巧合)*8:

- 1 <姓名> 佚名
- 2 <性别>不明确,TeX里的\empty、Lua里的nil、C里的0。
- 3 <政治面貌> 革命群众
- 4 <*教育背景>

^{*3} 不包括中文的全角空格,其属于汉字类别。

^{*4} 实现使用<uchar.h>的标准化头文件来支持万国码,所以一个字符是 8 字节长度。

^{*5} 这些都是可以调整的,见 jstml.c 文件中对 MAXTOKEN、MAXTAG 等的宏定义。

^{*6} 实际上,是由于它的末尾被且仅被换行符界定。这由于平台差异会出现事故: WINDOWS 下换行符为<CR><LF>、而 MACINTOSH 和 UNIX 系为<CR>、POSIX 等不明确。故不一定支持使用 WINDOWS 系统构建项目。

^{*7} 当然是在输入的字符不超过那个栈的能力范围的情况下。

^{*8} 其中部分文字来源于黄新刚的『雷太赫排版系统简介』,被 GNU 许可证保护。

- 5 巴灵顿大学: 烈士 (工商管理) ——1927~1936
- 6 克莱登大学: 勇士(比较文学) --1921~1927
- 7 卧龙岗大学: 壮士(分子生物) ——1919~1921
- 清华学堂:博士(有机化学)——1911~1919
- → 京师大学堂:硕士(天体物理)——1898~1900
- 10 北洋大学: 学士(应用数学) --1895~1898
- 11 </教育背景>
- 12 <*业余爱好>
- 13 搬砖砌墙,割草喂猪;挖坑灌水,淫湿作画。
- 14 研经修佛,以目窥密;布施洗礼,濯尘安卧。
- 15 </业余爱好>
- 16 <*信>
- 17 最大之乘,最正之宗;自如之理,乃见真实;修无为福,
- 18 胜于布施;受持此经,功德无量;应现设化,亦非真实。
- 19 </信>
- 20 <注>午休时间谢绝来电。

4 PLAIN-TEX 样式文件使用指北

本文件就是一个宏集兼驱动文件。使用它可以将本标记语言输出的中间文件转为 PDF 文件输出,通过修改它还可以有不同样式的结果。默认的标题名非常蠢,强烈建议修改标题后使用(见 jsdvr.tex 文件中的注释)。

另,请注意它是用 PLAIN-TEX 而非 $PTFX 2_E$ 写的,所以别乱改,会出问题。也请使用 PLAINFX 编译。

5 Lua 自动化脚本

该自动化脚本供处理大批量的使用本标记语言写成的文本文件使用。只需要创建一个名为 jsindex.ind 的文本文件,并将需要处理的文件名(带扩展名)使用西文逗号/换行符分隔后写在该文件里。

随后就可以使用 Lua 的独立解释器执行名为 jstml-auto.lua 的文件了。如果一切正常,幸运与你常在的话等一会就会凭空多出一个 PDF 格式的文件,这就是最终的输出了。如果报错,能自己解决最好,不行就开 issue。